SQL Data Cleaning for Reporting

Autor:
Jan Gombala

Ziel des Projekts:
Bereinigung eines fehlerhaften Datensatzes zur Vorbereitung für Reporting und Business Intelligence Analysen

Durchgeführte Schritte:

Standardisierung der Spaltennamen
Konvertierung der Datumsformate
Behandlung fehlender Werte
Entfernung leerer Textfelder
Identifikation und Entfernung doppelter Datensätze
Validierung numerischer Werte (Sales)
Prüfung der Datumslogik

Tools:
MySQL · SQL

Datum: März 2026

Inhalt

1. SQL Data Cleaning Script 3
1.1. Erstellung einer Arbeitskopie des Datensatzes 3
1.2. Standardisierung der Spaltennamen 3
1.3. Konvertierung der Datumsformate 4
1.4. Identifikation fehlender Werte und leerer Textfelder 5
1.5. Vereinheitlichung fehlender Textwerte 5
1.6. Überprüfung der Konsistenz kategorialer Variablen 6
1.7. Entfernung unnötiger Leerzeichen in Textfeldern 6
1.8. Identifikation und Entfernung doppelter Datensätze 7
1.9. Überprüfung numerischer Werte (Sales) 8
1.10. Prüfung der Datumslogik 9
1.11. Erstellung der finalen Reporting-Tabelle 9
2. Abschluss: Datenvisualisierung in Power BI 10
2.1. Management Dashboard Superstore Analyze: 10
2.2. Superstore Managment Summary: 11

1. SQL Data Cleaning Script

-- ==========

-- SQL Data Cleaning Projekt: Superstore Dataset

-- Ziel: Bereinigung eines fehlerhaften Sales-Datensatzes

-- für Reporting- und Analysezwecke

-- ==========

-- ==========

1.1. Erstellung einer Arbeitskopie des Datensatzes

-- ==========

- **Beschreibung:** Bevor ich mit der Bereinigung beginne, erstelle ich eine Kopie der Originaltabelle.
- **Grund:** Dies ist ein Best-Practice-Schritt, um die Rohdaten (Raw Data) zu schützen, falls Schritte rückgängig gemacht werden müssen.

```
CREATE TABLE superstore_dirty_clean AS
SELECT *
FROM superstore_dirty;


-- Kontrolle der Anzahl der Datensätze

SELECT COUNT(*)
FROM superstore_dirty_clean;
```

-- ==========

1.2. Standardisierung der Spaltennamen

-- ==========

- **Beschreibung:** Umbenennung von Spaltennamen durch Ersetzen von Leerzeichen durch Unterstriche (_) und Definition technischer Datentypen.
- **Grund:** Leerzeichen in Spaltennamen können bei komplexen Abfragen zu Fehlern führen. Ein einheitliches Namensschema (Snake Case) verbessert die Lesbarkeit und Handhabung im SQL-Editor.

```
ALTER TABLE superstore_dirty_clean CHANGE `Row ID` Row_ID INT;
ALTER TABLE superstore_dirty_clean CHANGE `Order ID` Order_ID TEXT;
ALTER TABLE superstore_dirty_clean CHANGE `Order Date` Order_date TEXT;
ALTER TABLE superstore_dirty_clean CHANGE `Ship Date` Ship_date TEXT;
ALTER TABLE superstore_dirty_clean CHANGE `Ship Mode` Ship_mode TEXT;
ALTER TABLE superstore_dirty_clean CHANGE `Customer ID` Customer_ID TEXT;
ALTER TABLE superstore_dirty_clean CHANGE `Customer Name` Customer_name TEXT;
ALTER TABLE superstore_dirty_clean CHANGE `Postal Code` Postal_code TEXT;
ALTER TABLE superstore_dirty_clean CHANGE `Product ID` Product_ID TEXT;
ALTER TABLE superstore_dirty_clean CHANGE `Product Name` Product_name TEXT;
```

-- ==========

1.3. Konvertierung der Datumsformate

-- ==========

- **Beschreibung:** Transformation der als Text gespeicherten Daten in echte DATE-Objekte mittels STR_TO_DATE.
- **Grund:** Datumsfunktionen (wie Monatsextraktion oder Zeitreihenanalysen) funktionieren nur, wenn das Feld korrekt als Datum formatiert ist.

```
SET SQL_SAFE_UPDATES = 0;

UPDATE superstore_dirty_clean
SET Order_date = STR_TO_DATE(TRIM(Order_date), '%d/%m/%Y');

ALTER TABLE superstore_dirty_clean
MODIFY Order_date DATE;

UPDATE superstore_dirty_clean
SET Ship_date = STR_TO_DATE(TRIM(Ship_date), '%d/%m/%Y');

ALTER TABLE superstore_dirty_clean
MODIFY Ship_date DATE;
```

-- ==========

1.4. Identifikation fehlender Werte und leerer Textfelder

-- ==========

- **Beschreibung:** Systematische Suche nach NULL-Werten oder leeren Textfeldern in kritischen Spalten wie Customer_name, City oder Category.
- **Grund:** Fehlende Daten können Kennzahlen verfälschen. Dieser Schritt dient der Qualitätskontrolle vor der Korrektur.

```
SELECT *
FROM superstore_dirty_clean
WHERE Customer_name IS NULL
   OR TRIM(Customer_name) = ''
   OR City IS NULL
   OR TRIM(City) = ''
   OR State IS NULL
   OR TRIM(State) = ''
   OR Region IS NULL
   OR TRIM(Region) = ''
   OR Category IS NULL
   OR TRIM(Category) = ''
   OR Product_name IS NULL
   OR TRIM(Product_name) = '';
```

-- ==========

1.5. Vereinheitlichung fehlender Textwerte

-- ==========

- **Beschreibung:** Ersetzung von ungültigen Zeichenfolgen durch NULL und anschließende Befüllung mit Standardwerten wie 'Unknown'.
- **Grund:** Sicherstellung, dass Berichte keine leeren Zeilen enthalten und die Datenintegrität gewahrt bleibt.

```
UPDATE superstore_dirty_clean
SET Customer_name = NULL
WHERE Customer_name NOT REGEXP '[a-zA-Z0-9]';

-- Fehlende Werte werden durch Standardwert ersetzt
```

```
UPDATE superstore_dirty_clean
SET Customer_name = 'Unknown'
WHERE Customer_name IS NULL;

UPDATE superstore_dirty_clean
SET Region = 'Unknown'
WHERE Region IS NULL;
```

-- ==========

1.6. Überprüfung der Konsistenz kategorialer Variablen

-- ==========

- **Beschreibung:** Einsatz von SELECT DISTINCT, um die Einzigartigkeit und Schreibweise von Kategorien wie Region, Country oder Segment zu prüfen.
- **Grund:** Identifikation von Tippfehlern (z. B. "Germany" vs. "Grmany"), die die Gruppierung in Analysen stören würden.

```
SELECT DISTINCT Region FROM superstore_dirty_clean;
SELECT DISTINCT Country FROM superstore_dirty_clean;
SELECT DISTINCT Category FROM superstore_dirty_clean;
SELECT DISTINCT City FROM superstore_dirty_clean;
SELECT DISTINCT Segment FROM superstore_dirty_clean;
```

-- ==========

1.7. Entfernung unnötiger Leerzeichen in Textfeldern

-- ==========

- **Beschreibung:** Bereinigung von Textfeldern (speziell City) von führenden oder abschließenden Leerzeichen mit der TRIM-Funktion.
- **Grund:** " New York" und "New York" werden von SQL als unterschiedliche Städte behandelt. Trimming verhindert Dubletten in der Gruppierung.

```
SELECT DISTINCT City
FROM superstore_dirty_clean
WHERE City <> TRIM(City);
UPDATE superstore_dirty_clean
SET City = TRIM(City)
WHERE City <> TRIM(City);
```

-- ==========

1.8. Identifikation und Entfernung doppelter Datensätze

-- ==========

- **Beschreibung:** Suche nach identischen Datensätzen basierend auf Order_ID und Product_ID und anschließendes Neuerstellen der Tabelle ohne Duplikate.
- **Grund:** Doppelte Buchungen führen zu künstlich aufgeblähten Umsatzzahlen (Sales-Inflaton).

```
SELECT Order_ID, Product_ID, COUNT(*)
FROM superstore_dirty_clean
GROUP BY Order_ID, Product_ID
HAVING COUNT(*) > 1;

-- Erstellung einer neuen Tabelle ohne vollständige Duplikate

CREATE TABLE superstore_deduplicated AS
SELECT DISTINCT *
FROM superstore_dirty_clean;

-- Kontrolle der Datensatzanzahl nach Bereinigung

SELECT COUNT(*)
FROM superstore_deduplicated;

-- Alte Tabelle ersetzen

DROP TABLE superstore_dirty_clean;

RENAME TABLE superstore_deduplicated TO superstore_dirty_clean;
```

-- ==========

1.9. Überprüfung numerischer Werte (Sales)

-- ==========

- **Beschreibung:** Validierung der Spalte Sales auf unplausible Werte (z. B. Werte ≤ 0 oder unrealistisch hohe Ausreißer).
- **Grund:** Ausreißer oder fehlerhafte negative Beträge verfälschen den Durchschnittsumsatz und andere statistische Kennzahlen.

```
SELECT MIN(Sales), MAX(Sales)
FROM superstore_dirty_clean;

-- Identifikation unplausibler Werte

SELECT *
FROM superstore_dirty_clean
WHERE Sales <= 0
   OR Sales >= 100000;

-- Korrektur der Ausreißer

UPDATE superstore_dirty_clean
SET Sales = NULL
WHERE Sales <= 0
   OR Sales >= 100000;

-- Kontrolle nach Bereinigung

SELECT *
FROM superstore_dirty_clean
WHERE Sales IS NULL;
```

-- ==========

1.10. Prüfung der Datumslogik

-- ==========

- **Beschreibung:** Validierung, ob das Versanddatum (Ship_date) zeitlich nach dem Bestelldatum (Order_date) liegt.
- **Grund:** Ein Versand vor der Bestellung ist logisch unmöglich und deutet auf Fehler bei der Dateneingabe hin.

```
SELECT *
FROM superstore_dirty_clean
WHERE Order_date > Ship_date;
```

-- ==========

1.11. Erstellung der finalen Reporting-Tabelle

-- ==========

- **Beschreibung:** Zusammenführung aller bereinigten Daten in einer finalen Struktur (superstore_reporting), die für Endnutzer optimiert ist.
- **Grund:** Trennung zwischen dem Bereinigungsprozess (Staging) und dem fertigen Datenprodukt für die Analyse.

```
CREATE TABLE superstore_reporting AS
SELECT
    Row_ID,
    Order_ID,
    Order_date,
    Ship_date,
    Ship_mode,
    Customer_ID,
    Customer_name,
    Segment,
    Country,
    City,
    State,
    Postal_code,
    Region,
    Product_ID,
    Category,
    Product_name,
    Sales
FROM superstore_dirty_clean;
```

---

2. Abschluss: Datenvisualisierung in Power BI

Nach der erfolgreichen Bereinigung in MySQL wurden die Daten in **Power BI** importiert. Ziel war es, ein interaktives Dashboard zu erstellen, um die wichtigsten Geschäftszahlen (KPIs) schnell und klar zu präsentieren.

In diesem Dashboard werden folgende Punkte analysiert:

- **Wichtige Kennzahlen:** Gesamtumsatz, Anzahl der Bestellungen und Kundenbasis.
- **Umsatz-Trends:** Die Entwicklung der Verkäufe über die Jahre 2015 bis 2018.
- **Kategorien & Regionen:** Verteilung der Umsätze nach Produktgruppen und geografischen Märkten.
- **Top-Performer:** Identifikation der meistverkauften Produkte und der bevorzugten Versandarten.

2.1. Management Dashboard Superstore Analyze:

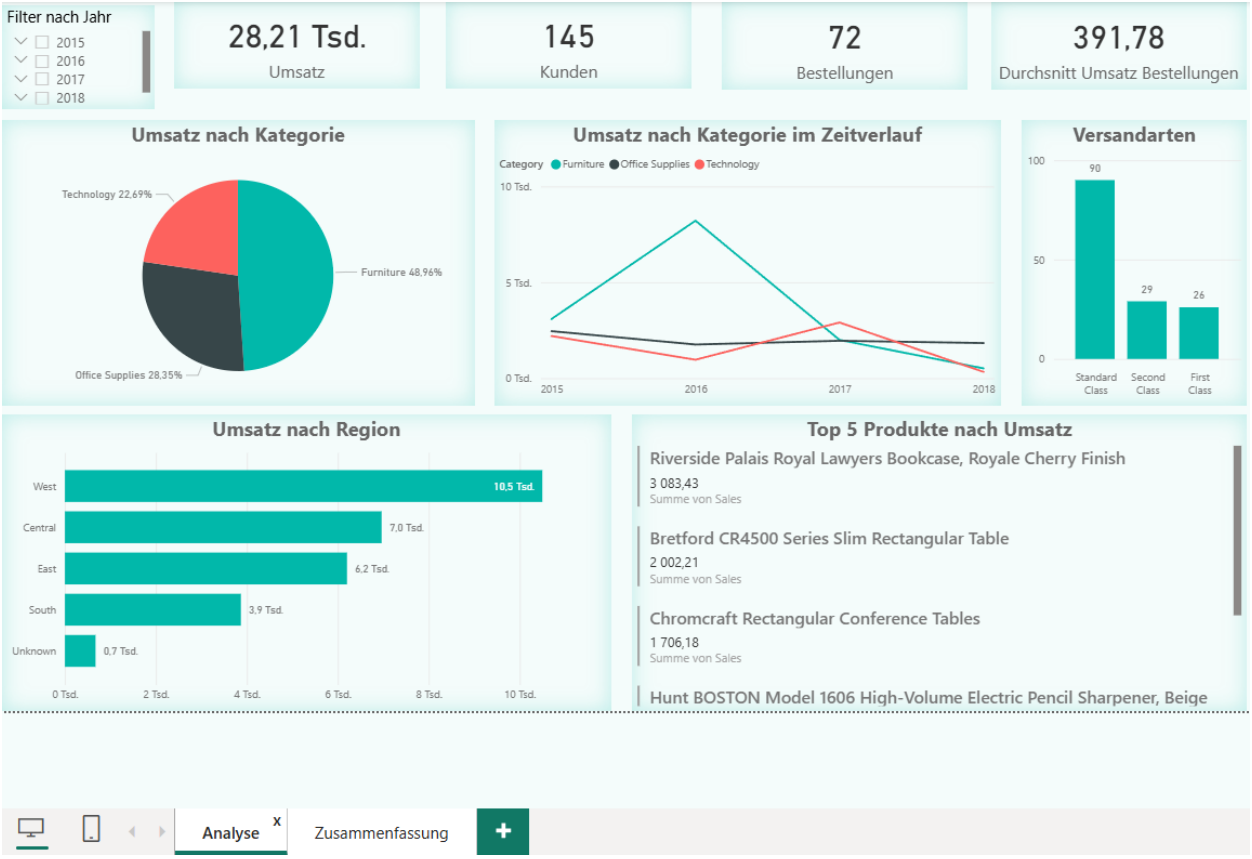

2.2. Superstore Management Summary:

1.Die umsatzstärkste Kategorie ist Furniture, sie macht fast die Hälfte des gesamten Umsatzes aus. Besonders das Jahr **2016 hatte einen großen Einfluss auf dieses Ergebnis**, während der Umsatzverlauf in den anderen Jahren zwischen den Kategorien relativ stabil bleibt.

2.Die meisten Bestellungen werden mit der Versandart Standard Class verschickt, was auf eine klare Präferenz für diese Versandoption hinweist.

3.Die umsatzstärkste Region ist mit deutlichem Abstand der Westen (West). Gleichzeitig zeigt sich, dass die Datenbank teilweise unvollständige oder nicht eindeutig zuordenbare Einträge enthält. Dies wird durch die Kategorie **"Unknown"** sichtbar.

4.Das Top-Produkt ist „Riverside Palais Royal Lawyers Bookcase“, das einen deutlichen Umsatzvorsprung gegenüber den anderen Produkten aufweist.

Analyse | Zusammenfassung x +